


온디바이스 AI 2026

엣지로 내려온 인공지능, 무엇이 달라지는가



Contents

한눈에 보기 — 엡지로 내려온 AI	3
가능케 한 기술 — NPU와 경량화	7
스마트폰과 PC — AI폰·AI PC의 실체	11
확장 영역 — 웨어러블·차량·로봇	15
왜 내려오는가 — 프라이버시·비용·지연의 경제학	19
전망과 시사점	23

01

한눈에 보기 — 엣지로 내려온 AI

클라우드에 있던 인공지능이 기기 안으로 들어오고 있다. 이 리포트가 다루는 변화의 전체 지형을 요약한다.

인공지능의 중심은 오랫동안 데이터센터에 있었다. 기기는 입력을 수집해 서버로 보내고, 서버가 대규모 모델을 실행한 뒤 결과를 돌려주는 구조가 기본값이었다. 이 방식은 막대한 연산 자원을 한곳에 모을 수 있다는 장점이 있었지만, 연결 상태와 전송 지연, 데이터 이동 비용에 제품 경험이 좌우된다는 한계도 함께 지녔다. 사용자의 손안에 있는 기기는 대체로 입출력 창구이자 서비스 접점으로 남았다.

이제 일부 기능은 기기 안에서 입력을 해석하고 결과를 만든다. 스마트폰과 PC의 전용 연산 장치, 압축된 모델, 운영체제 수준의 AI 기능이 만나면서 변화는 눈에 보이는 제품 기능으로 나타난다. 온디바이스 AI는 클라우드를 대체한다기보다, 처리할 일을 어디에 둘지 다시 배분하는 전환으로 이해하는 편이 정확하다. 이 장은 그 재배분이 기술, 제품, 산업에 던지는 질문을 먼저 정리한다.

1.1 처리 위치가 바뀌면 제품의 기준도 바뀐다

온디바이스 AI에서 중요한 것은 모델이 물리적으로 사용자 가까이 있다는 점이다. 음성 of 일부 구간을 판별하거나 사진에서 대상을 찾고, 짧은 문장을 정리하는 일은 네트워크 왕복 없이 기기에서 수행할 수 있다. 그 결과 응답성은 통신 품질에 덜 흔들리고, 민감한 원본 데이터를 외부로 보내지 않는 설계의 선택지가 넓어진다. 다만 기기 내 처리가 곧바로 완전한 비공개 처리를 뜻하는 것은 아니며, 제품별 데이터 경로를 따로 확인해야 한다.

그러나 모든 작업이 기기로 옮겨가는 것은 아니다. 긴 맥락을 다루거나 큰 모델의 추론 능력이 필요한 과업, 최신 정보에 의존하는 요청은 여전히 서버의 장점을 활용한다. 따라서 실제 제품은 입력의 성격, 사용자의 동의, 연결 상태, 요구되는 품질을 기준으로 기기와 클라우드 사이를 오가는 하이브리드 구조에 가까워진다. 한 번의 요청 안에서 전처리와 개인화는 기기에서, 복잡한 생성과 검색은 서버에서 맡을 수 있다.

처리 위치의 선택은 기술 부품의 문제가 아니라 서비스 설계의 문제다. 개발자는 어떤 데이터가 기기 밖으로 나가는지, 오프라인에서 어디까지 기능이 유지되는지, 결과가 불확실할 때 어느 경로로 보완할지를 미리 정해야 한다. 사용자는 모델의 크기보다 기능이 언제 즉시 반응하고 언제 연결을 요구하는지에서 이 변화의 가치를 체감한다. 따라서 기능 설명과 권한 설정은 모델의 성능만큼 중요한 신뢰의 장치가 된다.

구분	기기 내 처리	클라우드 처리	하이브리드 처리
강점	낮은 왕복 지연, 데이터 이동 축소	큰 모델과 유연한 확장	과업별 강점을 조합
제약	전력·메모리·발열의 한계	연결과 전송 비용에 의존	경로 전환의 정책 설계 필요
적합한 일	즉시성, 개인 맥락, 반복 기능	고난도 생성, 최신 정보 활용	일상 기능과 복잡한 요청의 연계

1.2 성능 경쟁은 모델 크기보다 제약 관리에서 시작된다

온디바이스 AI의 핵심 자원은 연산 성능만이 아니다. 모델을 저장하고 실행할 메모리, 배터리로 감당할 전력, 지속 사용 중 제어해야 할 발열이 동시에 제품의 경계를 정한다. 같은 기능이라도 휴대전화, 노트북, 차량, 웨어러블 기기에서 가능한 범위가 다른 이유가 여기에 있다. 하드웨어가 제공하는 여유와 사용 환경의 제약을 함께 보는 것이 사양 경쟁을 해석하는 출발점이다.

3

온디바이스 AI의 설계는 연산 성능, 메모리 용량, 전력 예산이라는 세 제약을 함께 다룬다.

1.2.1 전용 칩과 경량화의 결합

이 변화의 기반에는 신경망 연산을 겨냥한 전용 처리 장치와 모델 경량화 기법이 있다. 전용 장치는 일반 연산 장치와 역할을 나누어 반복적인 행렬 연산을 더 효율적으로 처리하도록 돕는다. 한편 모델은 정밀도를 낮추거나, 불필요한 부분을 줄이거나, 작은 모델에 지식을 옮기는 방식으로 기기에 맞춰 조정된다. 이러한 최적화는 단순히 파일 크기를 줄이는 일이 아니라, 제한된 자원에서 허용할 품질의 기준을 정하는 과정이다.

그렇다고 전용 칩의 유무만으로 경험의 수준이 결정되지는 않는다. 운영체제가 앱에 제공하는 접근 방식, 모델을 안전하게 배포하고 갱신하는 체계, 특정 언어와 음성·이미지 입력에 대한 품질 검증이 함께 갖춰져야 한다. 하드웨어 사양표의 수치보다 실제 기능이 얼마나 일관되게 작동하는지가 경쟁의 기준이

된다. 특히 오류가 발생했을 때 사용자가 결과의 한계와 대체 경로를 이해할 수 있어야 기능은 일상적 도구가 된다.

1.3 소결 — AI는 사라지는 것이 아니라 가까워진다

온디바이스 AI는 인공지능을 작게 만든다는 말만으로 설명할 수 없다. 이는 데이터가 이동하는 경로와 응답이 만들어지는 시간을 다시 설계하는 일이다. 개인 기기는 더 많은 판단을 현장에서 수행하고, 클라우드는 기기가 감당하기 어려운 지식과 연산을 보완하는 역할로 재배치된다. 이 구도에서 기기의 가치는 화면과 센서를 넘어, 상황을 해석하는 계산의 장소로 확장된다.

이 재배치는 프라이버시, 비용, 성능을 하나의 문제로 묶는다. 기기 안에서 끝낼 수 있는 처리는 전송을 줄일 수 있지만, 제한된 자원 안에서 품질과 안정성을 확보해야 한다. 반대로 서버 의존도를 높이면 능력의 폭은 넓어지나, 연결성과 데이터 처리에 대한 설명 책임도 커진다. 어느 한쪽을 일률적으로 우위에 두기보다 과업별 균형을 설계하는 역량이 중요해진다.

이 리포트는 이러한 전체 지형을 여섯 개의 질문으로 나누어 살핀다. 다음 장에서는 NPU와 경량화가 어떤 기술적 타협 위에서 온디바이스 AI를 가능하게 하는지 검토한다. 이어 스마트폰과 PC, 그리고 웨어러블·차량·로봇으로 확장되는 적용 영역과 경제적·사회적 함의를 차례로 짚는다. 마지막에는 하이브리드 구조가 기업과 개발자에게 요구하는 준비 과제를 정리한다.

02

가능케 한 기술 — NPU와 경량화

온디바이스 AI를 가능하게 만든 두 축, 전용 신경망 처리 장치와 모델 경량화 기술을 짚는다.

온디바이스 AI는 모델을 단지 기기에 복사해 넣는 일이 아니다. 서버용 모델이 전제로 삼았던 넉넉한 전력, 냉각, 메모리와 네트워크 연결을 손바닥 크기의 기기 안에서 다시 설계해야 한다. 이 제약을 넘기 위해 연산을 맡는 하드웨어와 모델 자체를 다듬는 소프트웨어가 함께 발전했다. 전자가 NPU라면, 후자는 경량화 기술의 묶음이다.

두 측은 서로를 보완한다. 빠른 연산기만 있어도 모델이 메모리를 지나치게 차지하면 기기의 반응성은 떨어지고, 작은 모델만 있어도 범용 프로세서에서 처리하면 전력 소모가 커질 수 있다. 따라서 온디바이스 AI의 성능은 초당 연산 횟수 하나로 판단하기 어렵다. 모델의 표현 방식, 메모리 이동, 운영체제의 자원 배분까지 하나의 설계 문제로 보아야 한다.

2.1 NPU: 신경망 계산을 위한 전용 경로

CPU는 운영체제와 응용 프로그램의 다양한 명령을 유연하게 처리하고, GPU는 다수의 연산을 병렬로 수행하는 데 강점이 있다. NPU는 그 사이에서 신경망 추론에 반복적으로 등장하는 행렬 곱셈과 누산, 활성화와 연산을 효율적으로 처리하도록 설계된 전용 처리 장치다. 같은 작업을 더 적은 에너지로 끝내는 것이 핵심 목표다. 그래서 NPU의 가치는 최고 성능보다 **성능 대비 전력**에서 먼저 드러난다.

신경망 추론에서는 계산 자체만큼 데이터를 옮기는 비용이 중요하다. 가중치와 중간 결과를 외부 메모리에서 여러 번 읽어 오면 지연과 전력 소모가 함께 늘어난다. NPU는 연산 배열 가까이에 빠른 메모리를 두고, 데이터를 가능한 오래 내부에 머물게 하는 데이터 흐름을 사용한다. 이 구조는 사진 분류, 음성 인식, 실시간 번역처럼 같은 형태의 연산이 반복되는 작업에 특히 알맞다.

다만 NPU가 모든 AI 작업을 대신하지는 않는다. 모델에 포함된 연산이 NPU의 지원 범위와 맞지 않으면 일부 구간은 CPU나 GPU에서 처리될 수 있다. 처리 장치 사이의 전환은 추가적인 메모리 복사와 지연을 만들 수 있다. 개발자는 모델을 고를 때 정확도뿐 아니라 각 기기의 실행 환경에서 연산이 얼마나 연속적으로 배치되는지도 살펴야 한다.

50%

8비트 가중치 표현은 16비트 표현과 비교해 원소당 저장 공간을 절반으로 줄인다.

2.2 경량화: 작게 만들되 기능을 남기는 법

경량화의 출발점은 수치 표현을 줄이는 **양자화**다. 학습이나 추론에서 흔히 쓰이는 부동소수점 값을 더 적은 비트의 정수 또는 저정밀 형식으로 바꾸면 모델의 저장 공간과 메모리 대역폭 요구량을 낮출 수 있다. 값의 범위를 적절히 조정하지 않으면 정확도가 흔들릴 수 있으므로, 변환 뒤의 품질 검증이 필수다. 일부 경우에는 낮은 정밀도를 고려해 다시 학습하는 방식으로 손실을 보완한다.

다음은 불필요한 부분을 덜어 내는 방법들이다. 가지치기는 영향이 작은 가중치나 구조를 줄이고, 지식 증류는 큰 교사 모델의 출력 특성을 더 작은 학생 모델이 배우게 한다. 또한 입력 길이를 제한하고, 필요한 층만 호출하며, 작업에 맞는 작은 모델을 선택하는 일도 넓은 의미의 경량화에 속한다. 중요한 것은 모델 파일의 크기만이 아니라 실행 중 생성되는 중간 결과와 메모리 사용량까지 함께 낮추는 데 있다.

접근법	주된 대상	얻는 효과	유의할 점
양자화	가중치와 연산 정밀도	저장 공간-메모리 이동 감소	작업별 정확도 검증 필요
가지치기	영향이 작은 가중치 채널	계산량과 모델 규모 축소	하드웨어가 희소 구조를 활용해야 효과가 큼
지식 증류	모델 구조와 출력 특성	작은 모델의 품질 보완	교사-학생 모델의 과업 정합 필요
구조 설계	층 수, 입력 길이, 호출 경로	지연-메모리 직접 제어	사용의 기능 범위를 명확히 정해야 함

이 기법들은 단독으로 끝나지 않는다. 예를 들어 양자화한 모델이라도 지원하지 않는 연산을 많이 포함하면 NPU의 장점을 충분히 얻기 어렵다. 반대로 하드웨어가 특정 정밀도와 연산 패턴을 잘 처리하면 모델 설계자는 그 경로에 맞춰 구조를 조정할 수 있다. 경량화는 압축률 경쟁이 아니라, 목표 기기에서 요구 성능을 안정적으로 내기 위한 공동 최적화다.

2.3 소결 — 연산기와 모델은 한 시스템이다

온디바이스 시의 기반은 NPU와 경량화 기술의 결합에 있다. NPU는 반복적인 신경망 계산을 전력 효율적으로 수행할 길을 만들고, 경량화는 그 길을 지나는 데이터의 양을 줄인다. 둘 중 하나만으로는

체감 성능, 발열, 배터리 지속 시간의 균형을 맞추기 어렵다. 기기 안에서 AI가 자연스럽게 작동하려면 두 요소가 같은 목표를 향해야 한다.

이 관점은 제품의 평가 기준도 바꾼다. 연산 성능 수치가 높아도 실제 모델이 메모리에 들어가지 않거나, 처리 장치가 자주 바뀌면 사용자는 지연을 경험한다. 반대로 지나치게 축소된 모델은 빠르지만 필요한 문맥과 정확도를 잃을 수 있다. 결국 확인해야 할 것은 특정 부품의 이름이 아니라, 목표 과업이 제한된 전력과 메모리 안에서 얼마나 일관되게 완결되는가다.

다음 장에서는 이 기술적 토대가 스마트폰과 PC에서 어떤 제품 경험으로 나타나는지 살핀다. AI폰과 AI PC라는 이름은 널리 쓰이지만, 실제 효용은 기기 안에서 처리되는 과업의 범위와 품질에 따라 달라진다. 하드웨어의 존재만으로 기능의 완성도를 판단해서는 안 된다. 온디바이스 AI의 실체는 사용자가 반복적으로 마주하는 작업 흐름에서 드러난다.

03

스마트폰과 PC — AI폰·AI PC의 실체

제조사들이 내세우는 AI폰과 AI PC가 실제로 무엇을 하는지, 마케팅과 실질을 구분한다.

AI폰과 AI PC라는 명칭은 하나의 제품군이라기보다, 기기 안에서 인공지능 연산을 처리할 수 있다는 제조사의 약속에 가깝다. 이 약속에는 전용 연산장치, 운영체제 기능, 애플리케이션의 사용 경험이 함께 묶여 있다. 그러나 모든 기능이 기기 안에서 작동하는 것도, 전용 칩이 있다고 해서 곧바로 유용한 기능이 생기는 것도 아니다.

따라서 판단의 출발점은 이름이 아니라 작업의 흐름이다. 사진을 정리하거나 음성을 받아쓰는 일이 네트워크 없이도 가능한지, 입력 데이터가 어디로 가는지, 결과가 얼마나 빨리 돌아오는지를 보아야 한다. AI폰과 AI PC의 실체는 새로운 기기 종류라기보다 이 세 질문에 대한 설계상의 답이다.

3.1 AI폰은 무엇을 기기 안에서 하는가

스마트폰에서 온디바이스 AI는 이미 카메라와 음성 기능에서 오래전부터 쓰여 왔다. 장면을 인식해 촬영 설정을 보정하고, 얼굴·피사체를 분리하며, 음성을 텍스트로 바꾸는 작업이 대표적이다. 최근의 변화는 이러한 단일 기능을 넘어, 문장 요약·번역·이미지 생성처럼 생성형 모델의 결과를 화면 위 작업에 연결하려는 데 있다.

이때 NPU는 배터리와 발열 제약 안에서 반복적인 신경망 연산을 맡는다. 중앙처리장치와 그래픽처리장치만으로도 AI 작업은 가능하지만, 전용 경로를 쓰면 특정 추론을 더 낮은 전력으로 처리하도록 설계할 수 있다. 다만 모델 크기와 메모리 용량은 여전히 한계이므로, 긴 문서의 폭넓은 이해나 복잡한 생성 작업은 클라우드 처리와 결합되는 경우가 많다.

사용자가 체감하는 차이는 기능의 범위보다 **즉시성·연결성·데이터 경로**에서 나온다. 오프라인 번역이나 통화 중 자막처럼 네트워크가 불안정해도 이어져야 하는 기능은 온디바이스 처리의 장점이 뚜렷하다. 반대로 서버에서 최신 정보를 찾거나 큰 모델의 추론이 필요한 기능은 인터넷 연결과 계정, 제공 지역에 따라 경험이 달라질 수 있다.

3.2 AI PC의 기준은 칩보다 작업 배치에 있다

AI PC는 일반적으로 CPU·GPU에 더해 NPU를 갖춘 PC를 가리킨다. 화상회의의 배경 흐림과 시선 보정, 실시간 자막, 음성 받아쓰기, 이미지 효과처럼 지속적으로 실행되는 작업은 NPU에 잘 맞는다. 운영체제가 이 연산 경로를 제공하면 앱 개발자는 매번 클라우드 서비스를 호출하지 않고도 일부 기능을 구현할 수 있다.

40 TOPS

Microsoft가 Copilot+ PC의 NPU 요건으로 제시한 최소 연산능력이다.

그러나 TOPS는 특정 정수 연산 조건에서의 이론적 처리량을 나타내는 지표다. 서로 다른 모델, 메모리 대역폭, 전력 설정, 소프트웨어 최적화까지 한 숫자로 비교하지는 못한다. 구매 판단에서는 NPU 수치만 보지 말고, 필요한 기능이 해당 운영체제와 앱에서 실제로 로컬 실행되는지 확인하는 편이 타당하다.

PC의 장점은 스마트폰보다 큰 메모리와 저장공간, 키보드·파일·업무 도구가 한 환경에 모인다는 데 있다. 그만큼 회의 기록 정리, 문서 초안 작성, 미디어 검색처럼 여러 데이터 원본을 다루는 기능이 유력하다. 하지만 기업 환경에서는 모델이 로컬에서 작동해도 권한 관리, 보존 정책, 감사 기록의 문제가 남으므로 '기기 내 처리'만으로 보안이 완성되지는 않는다.

구분	주된 온디바이스 작업	클라우드 결합이 찾은 작업	확인할 기준
스마트폰	통화 자막, 번역, 카메라 보정, 사진 분류	복잡한 생성, 최신 정보 검색	오프라인 작동 여부와 데이터 전송 범위
AI PC	화상회의 효과, 음성 입력, 파일 ·화면 인식	대용량 문서 분석, 협업 기반 생성	NPU 지원 앱과 운영체제 기능의 제공 범위

3.3 명칭보다 기능의 경계를 읽어야 한다

스마트폰과 AI PC의 마케팅은 전용 칩, 높은 연산능력, 개인화된 경험을 한데 제시한다. 실질은 그중 어떤 작업이 로컬 모델로 끝나고, 어떤 작업이 서버로 넘어가며, 사용자가 그 차이를 통제할 수 있는가에 달려 있다. 같은 제품 안에서도 기능별 실행 위치는 달라질 수 있고, 업데이트에 따라 그 경계도 바뀐다.

소비자에게 중요한 질문은 간명하다. 네트워크가 없어도 필요한 기능이 동작하는가, 민감한 입력이 외부로 전송되는가, 결과의 품질과 속도가 기존 방식보다 나아지는가를 확인해야 한다. 특히 '개인화'라는 표현은 기기 내 학습, 기기 내 검색, 서버 기반 프로필 처리를 서로 구분하지 않으면 실제 의미를 파악하기 어렵다.

결국 스마트폰과 AI PC는 독립된 혁명적 범주라기보다, AI 작업을 기기와 클라우드 사이에 다시 배치하는 전환점이다. NPU는 그 전환을 가능하게 하는 기반이지만, 가치를 결정하는 것은 접근 가능한 기능과

신뢰할 수 있는 데이터 처리 방식이다. 제조사의 명칭은 출발점일 뿐이며, 실제 사용 경험은 각 기능의 실행 장소와 조건에서 판별된다.

04

확장 영역 — 웨어러블·차량·로봇

손목과 차 안, 그리고 가정용 로봇까지. 온디바이스 AI가 다음으로 향하는 기기들을 살핀다.

온디바이스 AI의 다음 무대는 화면 앞에 앉아 있을 때만 작동하는 기기가 아니다. 손목의 센서, 주행 중인 차량, 거실을 오가는 로봇은 각기 다른 환경에서 끊임없이 신호를 받아야 한다. 이 기기들에서 현지 추론은 단순한 응답 속도 개선을 넘어, 상황을 놓치지 않기 위한 기본 설계가 된다.

확장의 공통점은 데이터가 더 개인적이고, 판단의 결과가 더 물리적이라는 데 있다. 웨어러블은 몸의 변화에, 차량은 주변 위험에, 로봇은 사람과 물체의 위치에 반응한다. 따라서 모델의 크기나 처리 성능만으로 가치를 판단하기보다 센서 신뢰성, 전력 예산, 실패했을 때의 안전한 동작을 함께 보아야 한다.

4.1 몸에 가까운 AI — 웨어러블의 상시성

웨어러블은 짧고 반복적인 신호를 오래 관찰하는 데 적합하다. 가속도계, 자이로스코프, 심박 센서처럼 기기에 이미 있는 입력을 조합하면 걸음, 수면, 운동 구간과 같은 패턴을 기기 안에서 먼저 가려낼 수 있다. 이때 온디바이스 AI는 모든 원시 데이터를 외부로 보내기보다, 필요한 순간에만 요약 결과를 제시하는 필터 역할을 한다. 사용자가 즉시 확인할 수 있는 짧은 피드백으로 바꾸는 과정도 현지 추론의 중요한 역할이다.

손목 위의 AI에서 중요한 자원은 연산량보다 배터리와 착용 경험이다. 작은 기기는 발열과 충전 주기에 민감하므로, 항상 큰 모델을 실행하는 방식은 적합하지 않다. 저전력 신호 감시가 후보 상황을 찾고, 그때만 더 정교한 분류를 수행하는 계층형 설계가 현실적인 이유다. 정확도와 전력 소비를 따로 최적화하지 않고, 사용 시간 전체에서 균형을 맞춰야 한다.

개인 건강과 관련된 추론은 특히 해석의 경계를 분명히 해야 한다. 센서값의 변화는 주의를 환기하는 단서가 될 수 있으나, 그 자체가 진단을 뜻하지는 않는다. 제품은 알림의 민감도와 사용자의 확인 절차를 함께 설계해야 하며, 오탐과 미탐을 줄이기 위한 데이터 품질 관리도 기기 내부의 모델만큼 중요하다.

4.2 움직이는 공간의 AI — 차량과 주변 인지

차량은 카메라와 레이더 등 여러 센서가 동시에 들어오는 이동형 컴퓨팅 환경이다. 제동·조향 보조나 운전자 상태 감지처럼 즉시성이 필요한 기능은 통신 상태에 따라 판단이 흔들려서는 안 된다. 그래서 차량 내 연산은 클라우드 서비스를 대체하기보다, 주행 중의 1차 판단과 안전한 제어를 맡는 층으로 자리 잡는다. 지도 갱신과 차량 관리처럼 시간이 덜 민감한 업무는 연결된 서비스와 나눠 맡길 수 있다.

6단계

SAE J3016은 도로 차량의 운전 자동화 수준을 레벨 0부터 5까지 여섯 단계로 구분한다.

이 분류는 온디바이스 AI가 곧 완전자율주행을 의미하지 않는다는 점을 선명하게 한다. 많은 기능은 운전자를 지원하는 범위에 있으며, 기능이 허용되는 도로·날씨·속도 조건과 운전자의 책임을 분리해 안내해야 한다. 현지 추론의 품질은 인식 정확도뿐 아니라, 확신이 낮을 때 운전자에게 넘기거나 기능을 제한하는 방식에서 드러난다.

기기 영역	기기 안에서 우선 처리할 신호	대표적 현지 추론	핵심 제약
웨어러블	생체·움직임의 연속 신호	활동 구간 분류, 이상 징후 알림	배터리, 센서 접촉 품질
차량	주변 환경과 운전자 상태	물체 인지, 경고, 제어 보조	안전성, 실시간성, 기능 조건
가정용 로봇	공간 영상, 거리, 음성 명령	장애물 회피, 물체 행동 인식	오인식, 개인정보, 물리적 충돌

4.3 소결 — 물리 세계의 신뢰를 설계하다

가정용 로봇은 온디바이스 AI의 난도를 가장 또렷하게 보여 준다. 로봇은 대화 내용을 이해하는 데서 그치지 않고, 방의 구조와 사람의 움직임을 파악한 뒤 실제로 이동하거나 물건을 다룬다. 네트워크가 끊긴 순간에도 멈추고 피하는 기본 동작이 유지되어야 하므로, 현지 추론은 편의 기능이면서 동시에 안전 장치다. 기기 내부에서 처리하는 범위가 넓을수록 생활 공간의 영상과 음성도 외부 전송 전에 더 엄격히 통제할 수 있다.

로봇의 핵심은 모든 상황을 기기 안에서 완벽하게 이해하는 데 있지 않다. 낯선 물체나 불확실한 명령을 만났을 때 동작 범위를 좁히고, 사람에게 확인을 요청하며, 위험한 행동을 보류하는 정책이 필요하다. 클라우드는 복잡한 질의, 소프트웨어 갱신, 장기 학습에 쓰일 수 있지만, 눈앞의 사람과 장애물에 대한 즉각적 판단은 기기 가까이에 남아야 한다.

웨어러블·차량·로봇의 확장은 온디바이스 시를 새로운 제품 범주가 아니라 설계 원칙으로 바꾼다. 입력에 가까운 곳에서 빠르게 판단하고, 민감한 원시 데이터를 불필요하게 이동시키지 않으며, 불확실할 때는 안전한 상태로 물러나는 원칙이다. 다음 경쟁은 더 큰 모델을 넣는 데서보다 제한된 전력과 공간 안에서 이 원칙을 얼마나 일관되게 구현하는가에 달려 있다.

05

왜 내려오는가 — 프라이버시·비용·지연의 경제학

데이터가 기기를 떠나지 않는 것의 가치와 클라우드 추론 비용 구조를 분석한다.

온디바이스 시의 확산은 단지 더 작은 모델을 기기에 넣는 기술 경쟁이 아니다. 데이터가 어디에서 처리되는지가 서비스의 신뢰, 운영비, 반응 품질을 함께 바꾸기 때문이다. 클라우드는 대규모 연산과 빠른 모델 갱신에 강하지만, 모든 요청을 원격 서버로 보내는 구조에는 네트워크와 운영이라는 고정된 마찰이 붙는다.

기기 내 추론은 이 마찰을 없애거나 줄이는 선택지다. 다만 그것이 클라우드의 대체를 뜻하지는 않는다. 민감도, 요청 빈도, 허용 지연, 모델의 크기를 기준으로 어느 경로에 계산을 둘지 결정하는 일이 새로운 설계 과제가 된다.

5.1 프라이버시는 데이터 경로의 문제다

개인정보 보호는 데이터를 암호화하는 문제만으로 끝나지 않는다. 음성, 카메라 영상, 위치, 입력 문장처럼 맥락이 풍부한 데이터는 그 자체로 사용자의 생활 패턴을 드러낼 수 있다. 기기 안에서 음성 인식이나 이미지 분류가 끝나면 원문을 원격 추론 서버로 보내지 않아도 되며, 전송·저장·접근 권한을 관리해야 하는 범위도 작아진다.

아이트

완전히 온디바이스에서 끝나는 추론은 입력 원문과 중간 표현을 외부 추론 서버로 전송하지 않는다.

그러나 온디바이스라는 말만으로 보호가 보장되지는 않는다. 결과를 동기화하거나 오류 분석을 위해 로그를 보내면 데이터 경로는 다시 열리며, 기기 분실과 악성 앱 접근은 별도의 위험으로 남는다. 따라서 제품은 처리 위치, 전송되는 항목, 보관 기간을 구분해 설명하고, 사용자가 원격 처리를 선택하거나 거부할 수 있게 해야 한다.

5.1.1 최소 전송이 만드는 설계 여지

데이터를 원천적으로 적게 움직이면 규제 대응도 단순해질 수 있다. 서비스 사업자는 수집 목적과 보관 범위를 좁힐 수 있고, 이용자는 연결이 불안정한 상황에서도 사적인 문서나 대화를 처리할 수 있다. 이는 법률상의 면책이 아니라, 민감한 입력이 불필요하게 시스템 경계를 넘지 않도록 하는 아키텍처상의 이점이다.

5.2 비용은 요청당 가격보다 구조를 본다

클라우드 추론 비용은 모델 실행 시간만으로 정해지지 않는다. 요청을 받는 서버, 가속기 용량, 네트워크 전송, 트래픽 급증에 대비한 여유 자원, 관측과 보안 운영이 함께 비용을 만든다. 이용자가 늘고 기능 호출 빈도가 높아질수록 이 비용은 서비스 제공자에게 반복적으로 발생한다.

반대로 온디바이스 추론은 계산 자원을 제품 가격과 전력 예산 쪽으로 옮긴다. 전용 NPU와 메모리는 초기 설계와 부품 원가에 영향을 주지만, 판매 뒤에 같은 작업을 처리할 때마다 중앙 서버의 연산을 추가로 확보할 필요는 줄어든다. 특히 짧고 반복적인 분류, 받아쓰기 보정, 개인화 추천처럼 요청 수가 많은 기능에서 이 차이가 뚜렷해진다.

판단 항목	온디바이스 우선	클라우드 우선	하이브리드 설계
민감한 원문	기기 안 처리	전송·보관 정책 필요	기본은 기기, 동의 시 확장
호출 빈도	반복 호출의 서버 부담 축소	호출마다 운영비 발생	단순 작업을 기기로 분산
모델 규모	메모리·전력 제약 큼	대형 모델 활용 용이	난도에 따라 경로 전환
갱신과 개선	배포·호환성 관리 필요	서버에서 즉시 반영 가능	핵심 모델과 보조 모델 분리

비용 비교에서 중요한 것은 어느 쪽이 항상 싸냐가 아니다. 기기 성능을 높이는 비용은 선행 투자에 가깝고, 클라우드 비용은 사용량과 함께 변동한다. 따라서 기업은 기능별 호출량, 기기 교체 주기, 전력 소모, 품질 개선의 속도를 한 묶음으로 계산해야 한다.

5.3 지연을 줄이는 것은 경험을 바꾸는 일이다

지연 시간은 통신망의 왕복 시간, 서버 대기열, 모델 실행, 결과 전송이 합쳐져 만들어진다. 클라우드 모델이 아무리 빠르게 계산해도 연결 품질이 흔들리면 응답 경험은 일정하지 않다. 온디바이스 처리는 이 가운데 네트워크 왕복과 원격 대기열을 제거하거나 우회하므로, 즉각 반응해야 하는 기능에 유리하다.

이 차이는 숫자 하나보다 사용 맥락에서 분명해진다. 키보드 입력을 고치거나 카메라 화면을 해석하고, 차량의 운전자 보조 기능이 주변 상황을 판단할 때 사용자는 응답을 기다리는 흐름을 원하지 않는다. 연결이 끊긴 상황에서도 최소 기능이 유지된다는 점은 편의성을 넘어 서비스 신뢰성의 일부가 된다.

5.3.1 소결: 위치가 아니라 배분의 경제학

온디바이스 AI의 가치는 프라이버시, 비용, 지연을 각각 개선하는 데서 출발하지만 실제 효용은 세 요소의 동시 최적화에 있다. 민감하고 자주 호출되며 즉시 반응해야 하는 작업은 기기 안에 둘 이유가 크다. 반면 최신 지식, 대규모 추론, 여러 사용자의 데이터를 결합해야 하는 작업은 클라우드의 장점이 여전히 크다.

결국 경쟁력은 모델을 어디에 두었다는 선언이 아니라, 요청의 성격에 맞춰 경로를 설계하는 능력에서 나온다. 기기에는 빠른 반응과 데이터 최소 전송을 맡기고, 클라우드에는 무거운 계산과 지속적 개선을 맡기는 구조가 현실적이다. 이 배분을 투명하게 설명하고 사용자가 통제할 수 있게 하는 제품이 온디바이스 전환의 신뢰를 얻을 것이다.

06

전망과 시사점

하이브리드 AI 구도의 향방과 기업·개발자가 지금 준비할 것을 정리한다.

온디바이스 AI의 확산은 클라우드 AI의 축소가 아니라 **추론 위치를 다시 배치하는** 일에 가깝다. 짧은 응답과 개인 맥락이 중요한 작업은 기기 안에서 처리하고, 넓은 지식과 큰 연산량이 필요한 작업은 원격 자원을 활용하는 구도가 자리 잡고 있다. 핵심은 어느 한쪽이 모든 일을 맡는지가 아니라, 요청마다 더 적합한 경로를 선택하는 능력이다.

따라서 기업의 판단 기준도 모델 크기나 단일 성능 지표에 머물러서는 안 된다. 데이터가 어디에 머물러야 하는지, 사용자가 어느 정도의 지연을 허용하는지, 연결이 끊겨도 제공해야 할 기능이 무엇인지를 함께 물어야 한다. 온디바이스 AI는 제품 기능인 동시에 데이터 흐름과 운영 책임을 재설계하는 계기가 된다.

6.1 하이브리드 AI는 역할 분담으로 고도화된다

기기 내 추론은 카메라·마이크·센서처럼 연속적으로 들어오는 신호에 특히 적합하다. 입력을 외부로 보내기 전에 분류하거나 요약하면 응답 경로가 짧아지고, 연결 상태의 영향을 덜 받는다. 반면 복잡한 문서 분석, 방대한 최신 정보의 결합, 다단계 추론은 클라우드의 확장 가능한 자원이 더 유리한 경우가 많다.

이 분업은 단순히 작은 모델과 큰 모델을 나누는 문제가 아니다. 서비스는 먼저 기기에서 가능한 범위를 판단하고, 신뢰도·작업 난도·사용자 동의 같은 조건이 충족될 때만 원격 처리를 호출해야 한다. 네트워크가 불안정하거나 원격 호출이 실패했을 때 제공할 축소 기능도 처음부터 설계해야 한다.

40 TOPS

마이크로소프트는 Copilot+ PC의 NPU 성능 요건으로 40 TOPS 이상을 제시했다.

구분	온디바이스 중심	클라우드 중심	하이브리드 설계
적합한 작업	즉시 반응, 개인화, 센서 처리	대규모 지식 활용, 복잡한 생성	요청 특성에 따른 동적 배분
데이터 원칙	원본을 기기에 우선 보관	필요한 정보를 원격 처리	민감도와 동의에 따라 최소 전송
운영 과제	기기 성능 편차, 모델 배포	비용, 지연, 연결 의존성	경로 선택, 품질 일관성, 장애 전환

시장의 경쟁은 단말에 NPU가 들어갔는지보다 이 경로 선택을 얼마나 자연스럽게 구현하는지에서 갈릴 가능성이 크다. 사용자는 처리 위치보다 응답의 품질, 속도, 통제 가능성을 경험한다. 그러므로 하이브리드 구조는 보이지 않는 인프라이면서도 제품 차별화의 핵심이 된다.

6.2 기업은 데이터와 운영 체계를 먼저 정비해야 한다

첫째, 기업은 AI 적용 후보를 기능 목록이 아니라 데이터 흐름으로 다시 분류할 필요가 있다. 개인 식별 정보, 음성·영상 원본, 위치처럼 외부 전송의 부담이 큰 데이터는 기기 내 처리를 우선 검토할 대상이다. 반대로 최신 사내 지식이나 여러 시스템의 통합 조화가 필요한 업무는 권한을 통제할 원격 처리가 더 현실적일 수 있다.

둘째, 배포 이후의 운영을 제품 요구사항에 포함해야 한다. 같은 기능도 칩셋, 운영체제, 메모리 여건에 따라 지연 시간과 출력 품질이 달라질 수 있다. 모델 경량화본의 버전, 지원 기기 범위, 원격 전환 조건을 함께 관리하지 않으면 현장에서는 서로 다른 경험이 누적된다.

셋째, 조달과 거버넌스의 질문도 달라져야 한다. 하드웨어의 연산 성능만 비교하기보다, 목표 기능이 실제 기기에서 달성하는 응답 시간·전력 사용·오류 대응을 검증해야 한다. 모델 업데이트의 책임 주체, 로그에 남는 데이터, 서비스 종료 시의 대체 경로를 계약과 운영 기준에 명시하는 일이 중요하다.

6.3 소결 — 개발자는 경로 선택을 제품 경험으로 구현해야 한다

개발의 출발점은 하나의 모델을 모든 환경에 밀어 넣는 일이 아니라, 작업을 나누는 인터페이스를 만드는 데 있다. 기기 모델과 원격 모델이 같은 입력·출력 규약을 따르도록 하고, 라우팅 계층이 성능·연결·동의 상태를 바탕으로 실행 위치를 결정하게 해야 한다. 이때 원격 호출은 기본 경로가 아니라 필요한 경우에만 쓰는 확장 경로로 설계하는 편이 견고하다.

평가 역시 두 환경을 분리해서 끝낼 수 없다. 대표 기기군, 저전력 상태, 네트워크 단절, 원격 응답 지연을 포함한 시나리오에서 동일한 작업 품질을 확인해야 한다. 개인정보가 포함될 수 있는 입력은 진단 로그와 오류 재현 과정에서 최소화하고, 사용자에게 실행 위치와 전송 여부를 이해하기 쉽게 알려야 한다.

향후의 우위는 가장 큰 모델을 보유한 기업보다, 각 요청을 알맞은 장소로 보내고 실패 시에도 신뢰를 유지하는 기업에 돌아갈 것이다. 기업은 데이터 분류와 운영 책임을 먼저 정리하고, 개발자는 이식 가능한 모델 경로와 측정 가능한 품질 기준을 구축해야 한다. 온디바이스 시는 클라우드를 대체하는 종착점이 아니라, AI 서비스를 더 가까운 곳에서 더 책임 있게 제공하기 위한 새로운 기본 구조다. 그 기준은 사용자가 자신의 데이터 흐름을 통제할 수 있는가에 있다.

온디바이스 시 2026 — 엣지로 내려온 인공지능, 무엇이 달라지는가
bookforge · 2026-08 · bookforge로 조판 · 수록 생성 이미지는 캡션에 표기